

苏坚生

AI 工程化落地负责人 / 技术总监及以上 | 深圳 (宝安) | 20 年研发 · 10 年管理

181-8862-8264 | sjs1919@qq.com | 微信 134-1072-8779 | 到岗: 在职可协商 | 薪资: 面议

个人概述 · Executive Summary

关键词: AI 工程化 | Agent 编排落地 | 多模型路由 | RAG | 团队 AI 转型 | 生产级交付

20 年研发管理功底, 近两年 All in AI 工程化——带队 3 周用 AI 全流程交付生产级跨境商城 (传统需 6 周), 把 Agent 从个人验证推成团队可落地的工程化能力, 自研多模型路由网关 token-hub 服务全公司研发。擅长把 AI 从概念变成可度量的交付能力。

关键成果快照 · Key Achievements

- ◆ **AI 生产交付:** 6 人小队 3 周交付 lexy 跨境商城 (常规约 6 周, 工期缩短约 50%); 测试周期从 2-3 周压缩到约 1 周 (TDD + AI 自动化验收); 2026.06 俄罗斯上线, 公司第一个 AI 全流程交付样板
- ◆ **Agent 工程化:** 4 周走完 Agent 全链路 (手写 ReAct → LangGraph 编排 → Supervisor 多 Agent → RAG + 规则引擎 → 评估闭环), 制造业排产 6 环节智能改造方案已在产线试运行
- ◆ **AI 基础设施:** 自研多模型路由网关 token-hub (统一管路由 / 计费 / 故障迁移, 已接入 Claude/Gemini/OpenAI + 智谱 GLM/Kimi/DeepSeek/通义千问等 10+ 主流模型, 服务全公司 24 名研发, 做内部 AI 成本优化)
- ◆ **团队 AI 转型:** 从个人验证 → 骨干最佳实践 → 团队规模化交付, 沉淀可复用 Vibe Coding playbook; 6 场 AI 培训覆盖 200+ 人, 立 AI 协作规范和能力路线图
- ◆ **工程底座:** 智能机器管理系统管 700+ 设备、7×24 无人值守; 运维排班从 5 人三班倒降到 2 人两班倒, 年释放约 3 人年盯守人力; 金融等保三级 + Agent 治理体系 (权限 / 审计 / 护栏)

核心能力 · Core Competencies

① AI 战略与落地 — 从 0 定标准到团队规模化交付

- AI 交付方法论沉淀: 将 Vibe Coding + TDD + AI 验收沉淀为可复用 playbook, 支撑 lexy 商城 3 周交付 (常规约 6 周, 工期缩短约 50%), 团队已继承迭代
- Agent 工程化推进: 4 周走完 ReAct→LangGraph→多 Agent 全链路, 制造业排产 6 环节方案已在产线试运行
- 团队 AI 转型: 6 场培训覆盖 200+ 人, 建立 AI 协作规范与能力路线图, 采用"骨干先行→最佳实践→团队扩散"路线

② AI 工程化与架构 — 稳定、合规、可演进的 AI 生产底座

- 多模型路由能力: 自研 token-hub 网关统一管路由/计费/故障迁移, 接入 10+ 主流大模型, 主模型额度耗尽自动切备份不降质, 服务全公司 24 名研发
- Agent 全链路工程化: ReAct→LangGraph(StateGraph)→Supervisor 多 Agent→Token Exchange 鉴权→权限/审计/护栏治理, 配套自研评估指标 (工具F1/完整性/订单命中)
- RAG 工程化: Milvus 向量库 + bge-large-zh 中文 embedding + BM25/向量混合检索 + RRF 融合 + Cross-Encoder 重排序, 支撑合同条款与履约文档语义检索
- 安全治理: Java MCP Server 鉴权/限流 + RBAC 权限 + 审计日志 + 护栏机制, 保障 AI 服务可控可追溯

③ 组织与人才规模化 — 把 AI 能力从个人变成团队体系

- 团队规模化管理: 经历从 0 建队、30+→150+ 扩编、空降整合多职能团队三种场景, 最大管理 150+ 跨职能研发
- 体系化交付能力: 双周迭代 + 7 工具闭环 + 绩效数据链路 (指标有出处、考核可追溯), 将救火团队转为体系驱动
- 人才梯队建设: 带出 4 名主管、3 名骨干、1 人连续晋升; AI 转型采用"愿者上钩"路线, 鼓励引导不强迫

工作经历 · Experience (倒序)

未来工场科技有限公司 | 研发总监 | 2022.04 - 至今

业务背景：空降接手覆盖多研发职能的团队（产品、Java 研发、测试、大数据、运维等，所辖 OMS / ERP 等业务系统），当时生产运营核心系统常年救火——重要需求能拖 2 个月，几乎每周都有突发故障。

核心职责：主导公司生产运营核心操作系统从 0 到 1 建设并规模到 700+ 设备；带团队走过“稳团队 → 建体系 → 转 AI”三段（2022–2024 主攻生产底座与研发体系，2024 起把 AI 工程化作为第二阶段主线），把 AI 工程化从个人验证变成团队可复用的交付能力。

lexy 商城 — AI 驱动全流程生产交付（核心项目）

- **立项授权：**领导从高管圈层感知 AI 编程趋势，既有期待又有顾虑；我以“自我验证 + 骨干小范围最佳实践 + 小项目累积可行性”同步可落地方案，用可行性证据争取到全盘用 AI 编程落地生产环境的授权
- **业务背景：**从 0 启动跨境电商新业务，需尽快验证俄罗斯市场
- **团队与节奏：**6 人小队（产品 / 前端 / 后端 / 测试 / 美工 + 我）3 周从需求到上线——第 1 周产品 + 我 + 业务方梳理用户故事，第 2–3 周我带前端 / 后端 / 美工并行落地并沉淀 Vibe Coding 方法论，测试全程 TDD 驱动做 AI 自动化测试 + 手工验收
- **AI 技术方案：**自研多模型路由网关 token-hub（统一管路由 / 计费 / 故障迁移，主模型月度额度耗尽自动切换备份、保障服务连续性不降质，接入 Claude、Gemini、OpenAI 及国内智谱 GLM、Kimi、DeepSeek、通义千问等 10+ 主流模型，服务全公司 24 名研发 + 个别业务人员）；TDD + AI 自动化验收（测试用例 AI 生成 + 人工审核，测试周期从常规 2–3 周压缩到约 1 周）；沉淀可复用交付 playbook（选型 → TDD → AI 验收 → 上线门禁），已由团队继承迭代
- **经营结果：**较同等 scope 常规交付节奏（约 6 周）快约一倍，工期缩短约 50%；团队投入约 3 人月（按实际到岗人周折算，约 12 人周，产品 / 美工为部分时间投入），较常规同规模排期工期成本约减半；2026.06 上线面向俄罗斯开售（公司第一个 AI 全流程交付样板）
- **商业价值：**3 周交付抢出市场窗口；新市场冷启动爬坡中，GMV 待爬坡验证、不夸大

企业级 Agent 排产助手 — 团队级工程化验证（核心项目）

- **业务背景：**制造业排产 6 环节（订单评审 → 物料 → 产能 → 进度 → 合同 → 调度）长期靠老师傅经验，慢且易错；目标是用多 Agent 协作把经验变成系统能辅助的决策
- **我的动作：**用 4 周集中攻关走完 Agent 全链路（手写 ReAct → LangGraph 编排 → Supervisor 多 Agent → Token Exchange 鉴权 + 权限 + 审计）——是个人把 Agent 从原理到工程化完整跑通的验证，非训练模型；基于 Python 完成端到端验证
- **RAG 检索增强（向量库选型与工程化·专项）：**企业内部知识库场景，选型评估五维度——①私有化部署（合同/履约数据不出公司）②中文检索效果③混合检索能力（合同编号/物料编码需精确匹配 + 条款语义召回）④运维复杂度⑤与 Java/Python 技术栈兼容；最终选型 Milvus（开源分布式向量库，HNSW 索引，私有化部署，搭配 bge-large-zh 中文 embedding）；检索层采用 BM25 关键词 + 向量语义混合检索 + RRF 融合排序，兼顾精确匹配与语义召回；工程化落地：文档按语义段落切片（200–500 字，重叠 50 字），元数据过滤（合同类型 / 客户 / 时间范围），Top-K 检索后 Cross-Encoder 重排序提升准确率
- **技术方案：**Agent 编排（LangGraph StateGraph 状态机 + Supervisor 多 Agent 分工）；规则引擎（单材料约束、坯件口径、耗料公式等真实业务规则计算，确保业务逻辑准确）；评估闭环（自研指标：工具 F1 / 完整性 / 订单命中）；治理体系（Java MCP Server 统一鉴权 / 限流 + RBAC 权限 + 审计日志 + 护栏机制，保障企业 Agent 服务可控可追溯）
- **经营结果：**排产 6 环节智能改造方案已在产线试运行，支撑核心排产环节；商业价值：排产从经验驱动转为数据 + AI 辅助，方向是用多 Agent 协作替代部分人工排产、缩短交付周期（当前为工程化验证阶段，尚未规模化铺开）

智能机器管理系统 — 生产运营核心操作系统（工程底座）

- **主导设计设备接入与调度核心系统，多品牌“热插拔”统一适配：**700+ 设备（3D 打印 330+ / 尼龙 60+ / 金属 50+ / CNC 250+）、7×24 无人值守、全国多区域多集群演进、健康度指标体系
- **价值：**改造前运维 3 班倒、5 人排班、随时准备救火；上线后基本 2 班倒、常态 2 人排班（晚班上下半夜各 1 人），年释放约 3 人年盯守人力

管理转型（接手时 → 现在）

- **接手时：**研发长期处于救火状态，重要需求延期 2 个月、每周必救火
- **现在：**双周迭代负载率稳定 70–90%、绩效数据链路贯通、团队正常上下班、质量基线内化；从被动救火转为主动按节奏交付
- **落地路径：**研发流程 v1→v2 + 敏捷 DevOps + 双周迭代 7 工具闭环 + 项目负责人机制 + 业务-研发双周例会，把研发从黑盒变透明
- **人才梯队：**价值观 + 绩效双维度盘点（季度盘点、年度晋升），带出 4 名主管、3 名骨干、1 人连续晋升

绿信集团（绿地金控旗下） | 资深架构师 → 研发总监 | 2016.11 - 2022.03

- **业务背景：**消费金融高速扩张期，要建 600 亿放款规模的平台

- **关键成果**：搭 Spring Cloud 微服务生态，把 .net 核心系统重构到 Java，支撑 600 亿放款 / 4300 万客户 / 87+ 资金方 / 40+ 流量方；过金融等保三级
- **平台底座改造（研发总监牵头）**：基础设施由物理机迁移至虚拟化 + 公有云混合云；构建 CI/CD 自动化流水线并落地 Docker 容器化；全面网络安全加固；文件存储由共享文件夹切换至 OSS，根治文件锁阻塞导致的卡机风险，支撑日 10 亿交易量平稳运行
- **我的贡献**：作为研发总监牵头组织研发部完成等保驱动的平台级改造；主导 Spring Cloud 重构与微服务生态搭建；金融等保三级落地中研发侧牵头，主导组织全公司跨部门按金融监管要求补齐合规文档体系；从资深架构师升任研发总监，组 30+ Java 团队扩到 150+ 跨职能
- **可迁移价值**：高并发高可用 + 多资金方接入架构，可直接迁移到 Agent 服务化平台

腾讯科技 MIG | 高级开发 / 组长 (3 次授予腾讯股票) | 2011.09 - 2015.09

- 作为项目负责人负责城市服务-网上营业厅核心服务模块，所在平台累计 4500 万绑定用户 / 1100 万月活 / 日均 PV 1200 万；T2.3 → T3.2 晋级
- **可迁移价值**：千万级高并发互联网架构 + 跨地域多团队协作，对应 AI 服务平台亿级消息处理能力

深圳市博思达供应链（收购网） | 技术总监 | 2015.10 - 2016.10（跨境创业公司，1 年期项目）

- 3 个月从 0 跑通跨境进口全链路，主导海关报备、通关、ERP、三单一证报关模块建设
- **可迁移价值**：多区域报关调度 + ERP 系统，对应制造业多品牌多产线调度

金蝶软件（中国） | 高级开发 / 项目经理 | 2006.10 - 2011.09

- 主导 CRM 核心模块设计与交付，带团队支撑多家集团客户管理业务；CRM 项目获集团创新奖，绩效持续优秀

自我评价 · Summary

20 年研发、10 年技术管理，跨金融 / 跨境 / 制造三大行业。近两年把企业级工程化能力迁移到 AI：先自己下场把 Vibe Coding 路径趟通，再组队交付生产级商城，最后把 Agent 从个人验证推成团队能落地的工程化能力。不靠堆人头，靠把方法沉淀成可复用的体系。擅长在业务和技术之间做翻译，把 AI 从概念变成可度量的交付成果。同时懂金融级合规、跨境电商全链路、制造业生产场景的 AI 工程化负责人——这是纯算法人才和纯管理人才都不具备的复合优势。

教育与技术栈 · Education & Tech

教育：武汉大学 (985 / 211) | 本科 | 软件工程 | 2003.09 - 2007.07

AI 工程技术栈：Agent 编排 (LangGraph / ReAct / Supervisor 多 Agent / MCP Server)；RAG 与检索 (文档切片向量检索、规则引擎融合、检索效果评估)；多模型路由 (自研 token-hub，接入 10+ 模型，统一路由 / 计费 / 故障迁移 / 成本优化)；AI 治理 (RBAC 权限、审计日志、护栏机制、Token Exchange 鉴权)；AI 评估 (自研指标：工具 F1 / 完整性 / 订单命中)；开发语言 (Python AI/Agent、Java 后端/MCP、Go)；Prompt 工程 (Vibe Coding 方法论、TDD + AI 自动化验收、可复用交付 playbook)

传统架构技术栈：Spring Cloud 微服务、高并发高可用架构、混合云 (虚拟化 + 公有云)、CI/CD + Docker、金融等保三级、DevOps 工具链、OSS 对象存储、设备接入与调度系统

证书：PMP 认证；多次优秀员工 / 优秀经理人 / 期权股权激励；跨行业沉淀：ERP → 互联网 → 跨境电商 → 消费金融 → 智能制造 → AI 工程化